Blackjack AI — Fonctionnement mathématique du modèle 1

Prédiction probabiliste du croupier et effet de son erreur sur l'agent hybride

Table des matières

1 Le problème d'apprentissage **2**
- 1.1 Données . . . 2
- 1.2 La carte visible suffit . . . 2
- 1.3 Ce qu'il faut estimer . . . 2

2 Évaluer une prédiction probabiliste **2**
- 2.1 Log-loss, entropie et divergence de Kullback-Leibler . . . 2
- 2.2 Score de Brier . . . 3
- 2.3 Exactitude . . . 3

3 La régression logistique multinomiale **4**
- 3.1 Le modèle . . . 4
- 3.2 Estimation . . . 4

4 Le cas d'une seule variable catégorielle **5**
- 4.1 Sans régularisation, la régression redonne les fréquences . . . 5
- 4.2 L'effet exact de la régularisation . . . 5

5 Erreur d'estimation et quantité de données **6**
- 5.1 Comportement asymptotique . . . 6
- 5.2 Comparaison avec les mesures . . . 7

6 De l'erreur des probabilités à l'erreur de décision **8**
- 6.1 Erreur sur la valeur de rester . . . 8
- 6.2 Conséquences pour la politique . . . 8

7 Protocole statistique **9**

8 Synthèse **9**

Ce document complète *Fonctionnement mathématique du modèle 2* (fichier `docs/modele2.pdf`), qui décrit le processus de décision markovien, le Q-learning hybride et la propagation d'une erreur du modèle 1 vers la politique. Nous en reprenons les notations : $P(c)$ désigne la loi d'une carte, d la carte visible du croupier, $D \in \mathcal{D} = \{17, 18, 19, 20, 21, \text{BUST}\}$ son résultat final et $R(p, D)$ le gain du joueur qui reste avec le total p. Le présent document traite de la partie statistique : ce que le modèle 1 estime, comment il l'estime, avec quelle précision en fonction du nombre de mains simulées, et comment cette précision se traduit en qualité de décision. Toutes les valeurs numériques citées proviennent des fichiers de résultats du dépôt ou ont été recalculées à partir des modèles livrés.

1 Le problème d'apprentissage

1.1 Données

On note $\mathcal{C} = \{1, \dots, 10\}$ l'ensemble des cartes visibles possibles et $K = |\mathcal{D}| = 6$ le nombre de résultats du croupier. Une simulation tire la carte visible d selon P, puis la carte cachée et les cartes suivantes, et applique la règle du croupier jusqu'à son arrêt. On obtient un exemple (d_i, D_i). Les n exemples d'un jeu de données sont indépendants et de même loi :

$$d_i \sim P, \qquad D_i \mid d_i \sim \pi_{d_i}, \qquad \text{où } \pi_d(k) = P(D = k \mid d).$$

On note n_d le nombre d'exemples de carte visible d, n_{dk} le nombre de ceux qui se terminent par le résultat k, et $f_d(k) = n_{dk}/n_d$ la fréquence observée correspondante.

1.2 La carte visible suffit

Proposition 1. *Dans un paquet infini, pour tout état $s = (p, d, a)$ dans lequel le joueur reste,*

$$P(D = k \mid s) = \pi_d(k) \qquad \textit{pour tout } k \in \mathcal{D}.$$

Démonstration. Toutes les cartes sont des tirages indépendants de loi P. Le résultat D est une fonction de la carte visible, de la carte cachée et des cartes que tire ensuite le croupier, car sa règle d'arrêt ne dépend que de sa propre main. Les cartes du joueur sont d'autres tirages, indépendants des précédents. Conditionnellement à d, le résultat D est donc indépendant de (p, a). □

Cette propriété justifie de simuler le croupier séparément du joueur et de ne donner au modèle que la carte visible. Elle cesserait d'être vraie avec un paquet fini, où les cartes déjà distribuées au joueur modifient la composition du paquet.

1.3 Ce qu'il faut estimer

Le modèle 1 doit estimer dix lois de probabilité $\pi_1, \dots, \pi_{10}$, chacune élément du simplexe

$$\Delta_K = \Big\{ q \in [0,1]^K : \sum_k q(k) = 1 \Big\}.$$

Chaque loi a $K - 1 = 5$ degrés de liberté, soit 50 paramètres libres au total. Il s'agit d'un problème d'estimation de faible dimension, pour lequel on dispose de dizaines de milliers d'exemples : on s'attend donc à une erreur faible, que la section 5 quantifie.

2 Évaluer une prédiction probabiliste

Une prédiction est une famille $q = (q_1, \dots, q_{10})$ de lois de Δ_K. On l'évalue par des *règles de score* qui comparent la loi annoncée au résultat observé.

2.1 Log-loss, entropie et divergence de Kullback-Leibler

Définition 1. La log-loss d'une prédiction q sur l'exemple (d, D) vaut $-\log q_d(D)$, en nats. Son espérance sous la vraie loi des données est le risque

$$\mathcal{R}(q) = \mathbb{E}\big[-\log q_d(D)\big] = -\sum_{d \in \mathcal{C}} P(d) \sum_{k \in \mathcal{D}} \pi_d(k) \log q_d(k).$$

Proposition 2 (Décomposition du risque)**.** *Pour toute prédiction q dont les probabilités sont strictement positives,*

$$\mathcal{R}(q) = H(D \mid d) + \sum_{d \in \mathcal{C}} P(d)\, \mathrm{KL}(\pi_d \,\|\, q_d),$$

où $H(D \mid d) = -\sum_d P(d) \sum_k \pi_d(k) \log \pi_d(k)$ est l'entropie conditionnelle du résultat et $\mathrm{KL}(\pi \,\|\, q) = \sum_k \pi(k) \log\big(\pi(k)/q(k)\big)$ la divergence de Kullback-Leibler.

Démonstration. On écrit $-\log q_d(k) = -\log \pi_d(k) + \log\big(\pi_d(k)/q_d(k)\big)$, puis on prend l'espérance sous π_d et sous P. □

La divergence de Kullback-Leibler est positive et ne s'annule que si les deux lois sont égales (inégalité de Gibbs). On en déduit trois conséquences.

1. Le risque est minimal pour $q = \pi$ et seulement pour elle : la log-loss récompense les probabilités exactes, ce que l'on exprime en disant que c'est une règle de score *strictement propre* [2].
2. La valeur minimale est l'entropie conditionnelle, qui vaut ici 1,6481 nat par main. Aucun modèle ne peut faire mieux en moyenne : cette part de la perte traduit le hasard des cartes, pas une imperfection du modèle.
3. Le second terme, appelé *excès de log-loss*, mesure seulement l'erreur du modèle. Comme π est connue exactement (section 2.1 du document du modèle 2), cet excès se calcule sans aucun jeu de test. Pour le modèle livré, il vaut 0,000429.

Remarque. La log-loss mesurée sur un jeu de test fini estime $\mathcal{R}(q)$ avec un bruit important. L'écart-type d'une perte individuelle vaut environ 0,55, donc celui d'une moyenne sur 12 000 mains vaut environ 0,005, soit douze fois l'excès à mesurer. C'est pourquoi la loi exacte elle-même peut obtenir une log-loss de test légèrement moins bonne qu'un modèle estimé (1,651709 contre 1,651587), et pourquoi les comparaisons utilisent l'excès exact ou des différences appariées sur les mêmes mains.

2.2 Score de Brier

Proposition 3. *Le score de Brier multiclasse $B(q) = \mathbb{E}\big[\sum_k \big(q_d(k) - \mathbf{1}[D = k]\big)^2\big]$ se décompose en*

$$B(q) = \sum_d P(d)\Big(\|q_d - \pi_d\|^2 + 1 - \|\pi_d\|^2\Big).$$

Démonstration. Pour d fixé et $Y_k = \mathbf{1}[D = k]$, on a $\mathbb{E}[Y_k] = \pi_d(k)$ et $\mathbb{E}\big[(q_d(k) - Y_k)^2\big] = (q_d(k) - \pi_d(k))^2 + \pi_d(k)(1 - \pi_d(k))$. On somme sur k en utilisant $\sum_k \pi_d(k) = 1$. □

Le score de Brier est donc lui aussi strictement propre. Sa part irréductible, $\sum_d P(d)(1 - \|\pi_d\|^2)$, vaut 0,7768 : comme pour la log-loss, la quasi-totalité du score observé (0,7785 sur le test) provient du hasard des cartes.

2.3 Exactitude

Un prédicteur qui annonce toujours le résultat le plus probable a pour exactitude

$$\sum_d P(d)\, \pi_d\big(\arg\max_k q_d(k)\big) \le \sum_d P(d) \max_k \pi_d(k) = 36{,}70\,\%.$$

La borne est atteinte dès que q_d et π_d ont le même mode pour chaque carte, quelle que soit la précision des autres probabilités. C'est le cas pour la régression, pour les fréquences et pour la loi exacte, qui obtiennent toutes trois 36,49 % sur le même jeu de test. L'exactitude ne permet donc pas de distinguer ces estimateurs ; elle n'évalue pas non plus les probabilités dont l'agent hybride a besoin.

3 La régression logistique multinomiale

3.1 Le modèle

La carte visible est représentée par le vecteur indicateur $x = e_d \in \{0,1\}^{10}$ (encodage *one-hot*). Le modèle associe à chaque résultat k un vecteur de poids $w_k \in \mathbb{R}^{10}$ et un biais $b_k \in \mathbb{R}$. Comme $w_k^\top e_d = w_{k,d}$, le score du résultat k pour la carte d vaut $z_k(d) = w_{k,d} + b_k$, et la probabilité prédite est donnée par la fonction *softmax* [3] :

$$q_d(k) = \frac{\exp\left(w_{k,d} + b_k\right)}{\sum_{j \in \mathcal{D}} \exp\left(w_{j,d} + b_j\right)}.$$

Les paramètres forment une matrice $W \in \mathbb{R}^{6\times 10}$ et un vecteur $b \in \mathbb{R}^6$, soit 66 nombres pour 50 degrés de liberté : ajouter une même constante à tous les scores d'une carte ne change pas ses probabilités. La régularisation, décrite ci-dessous, sélectionne une représentation parmi toutes celles qui donnent les mêmes probabilités.

3.2 Estimation

Avec le solveur L-BFGS, scikit-learn minimise

$$\mathcal{L}_C(W,b) = \frac{1}{2}\|W\|_F^2 + C\sum_{i=1}^{n} -\log q_{d_i}(D_i),$$

où $\|W\|_F^2 = \sum_{k,d} w_{k,d}^2$ et où les biais ne sont pas pénalisés. Diviser par Cn montre qu'il s'agit de minimiser la log-loss moyenne d'entraînement plus la pénalité $\|W\|_F^2/(2Cn)$: plus C est petit, plus la pénalité est forte. De manière équivalente, (W,b) est l'estimateur du maximum a posteriori lorsque chaque poids suit a priori une loi normale centrée de variance C. La forme exacte de cet objectif a été vérifiée numériquement à travers sa condition d'optimalité (proposition 6).

Proposition 4 (Convexité et gradient)**.** *La fonction $\mathcal{L}_C$ est convexe, et strictement convexe en W. Ses dérivées partielles valent*

$$\frac{\partial \mathcal{L}_C}{\partial w_{k,d}} = w_{k,d} + C\, n_d(q_d(k) - f_d(k)), \qquad \frac{\partial \mathcal{L}_C}{\partial b_k} = C\sum_d n_d(q_d(k) - f_d(k)).$$

Démonstration. La perte d'un exemple s'écrit $-z_{D_i}(d_i) + \log\sum_j \exp z_j(d_i)$. La fonction $\log\sum\exp$ est convexe et les scores sont affines en (W,b), donc la perte est convexe ; le terme $\frac{1}{2}\|W\|_F^2$ est strictement convexe en W. La dérivée de la perte d'un exemple par rapport à z_k vaut $q_{d_i}(k) - \mathbf{1}[D_i = k]$. Seuls les exemples de carte d font intervenir $w_{k,d}$; leur somme donne $n_d\, q_d(k) - n_{dk} = n_d(q_d(k) - f_d(k))$. Le biais b_k intervient dans tous les exemples, d'où la somme sur d. □

Annuler ce gradient conduit à des équations non linéaires, car q_d dépend de W et de b à travers la softmax. Il n'existe pas de formule explicite pour C fini, et l'optimum est calculé numériquement par L-BFGS, une méthode de quasi-Newton qui approche la courbure de l'objectif à partir des gradients successifs [4]. La convexité garantit que le minimum trouvé est global.

Remarque (Ce n'est pas une méthode des moindres carrés). Les moindres carrés ajustent une fonction linéaire en minimisant une somme d'écarts quadratiques ; leurs prédictions ne sont pas contraintes à former des probabilités. La régression logistique maximise au contraire la vraisemblance d'un modèle de probabilités, ce qui revient à minimiser la log-loss. Les deux approches coïncident toutefois dans le cas particulier étudié ici : avec une seule variable catégorielle, une régression linéaire des indicatrices $\mathbf{1}[D = k]$ sur l'encodage one-hot donne elle aussi les fréquences $f_d(k)$, qui sont les moyennes de ces indicatrices dans chaque catégorie. Les deux méthodes ne divergent qu'en présence de plusieurs variables explicatives.

4 Le cas d'une seule variable catégorielle

4.1 Sans régularisation, la régression redonne les fréquences

Proposition 5 (Modèle saturé)**.** *Supposons $n_{dk} > 0$ pour toute carte d et tout résultat k. Alors la log-loss d'entraînement $\sum_i -\log q_{d_i}(D_i)$ atteint son minimum exactement lorsque $q_d = f_d$ pour toute carte d.*

Démonstration. En regroupant les exemples par carte, puis en appliquant la proposition 2 à la loi empirique,

$$\sum_{i=1}^{n} -\log q_{d_i}(D_i) = \sum_{d} n_d \Big(H(f_d) + \mathrm{KL}(f_d \,\|\, q_d) \Big).$$

Le premier terme ne dépend pas du modèle et le second est minimal, égal à zéro, si et seulement si $q_d = f_d$ pour chaque d. Cette valeur est atteignable : il suffit de prendre $b = 0$ et $w_{k,d} = \log f_d(k)$, ce qui est possible car toutes les fréquences sont strictement positives. □

Le modèle est dit *saturé* : il peut représenter n'importe quelle famille de dix lois strictement positives, et rien ne relie les estimations des différentes cartes. Si un résultat n'était jamais observé pour une carte, la fréquence correspondante serait nulle, valeur qu'une softmax ne peut pas atteindre, et les poids divergeraient. Dans le jeu d'entraînement livré, le plus petit effectif n_{dk} vaut 278 : la situation ne se produit pas.

4.2 L'effet exact de la régularisation

Proposition 6. *Au minimum de $\mathcal{L}_C$, pour toute carte d et tout résultat k,*

$$q_d(k) - f_d(k) = -\frac{w_{k,d}}{C\, n_d} \qquad \text{et} \qquad \sum_{d \in \mathcal{C}} w_{k,d} = 0.$$

En particulier, $\sum_d n_d\, q_d(k) = \sum_d n_{dk}$: le modèle reproduit exactement la fréquence globale de chaque résultat dans l'échantillon d'entraînement.

Démonstration. On annule les dérivées de la proposition 4. La dérivée par rapport à $w_{k,d}$ donne la première égalité. La dérivée par rapport à b_k donne $\sum_d n_d(q_d(k) - f_d(k)) = 0$; en y remplaçant chaque terme par $-w_{k,d}/C$, on obtient la seconde. □

Cette proposition décrit entièrement l'effet de la régularisation. Lorsque les poids sont nuls, toutes les cartes reçoivent la même loi, $\mathrm{softmax}(b)$; la pénalité attire donc chaque q_d vers une loi commune à toutes les cartes. L'écart aux fréquences est inversement proportionnel à $C\, n_d$: il est plus marqué pour les cartes rares et pour les petites valeurs de C.

Pour le modèle livré, l'identité a été vérifiée sur les soixante probabilités avec un écart maximal de $1{,}5 \times 10^{-7}$, dû à la tolérance de l'optimiseur. Avec $C = 0{,}1$ et n_d compris entre 4 546 et 18 374, on a $C\, n_d \geq 454$, et le plus grand écart entre la régression et les fréquences vaut 0,0026. Cette proposition explique trois observations du projet.

1. *Le choix de C importe peu.* Pour $C \geq 0{,}1$, les écarts aux fréquences sont trop petits pour modifier la log-loss de validation au-delà de la sixième décimale. Pour $C = 0{,}01$, ils sont dix fois plus grands et la log-loss de validation se dégrade nettement (1,641715 contre 1,641194).
2. *La régression et les fréquences ont la même qualité.* Leur excès de log-loss diffère de 0,00002 à 60 000 mains, alors que l'excès lui-même vaut 0,0004.
3. *Les deux agents hybrides prennent presque toujours les mêmes décisions.* D'après le lemme sur la variation totale du document du modèle 2, les valeurs de STAND calculées avec la régression et avec les fréquences diffèrent d'au plus $2 \max_d \mathrm{TV}(q_d, f_d) = 0{,}0053$. Les deux

politiques ne peuvent donc différer que dans des états où les valeurs de HIT et de STAND sont presque égales, ce qui est cohérent avec les gains identiques observés sur 18 des 20 graines de l'ablation.

Remarque (Quand la régression serait-elle utile ?). L'intérêt d'un modèle paramétrique apparaît lorsqu'il n'est pas saturé, c'est-à-dire lorsque le nombre de situations possibles est grand devant le nombre de paramètres. Avec un paquet fini, par exemple, la loi du croupier dépendrait aussi des cartes déjà sorties ; les combinaisons possibles seraient trop nombreuses pour être estimées séparément, et un modèle qui partage l'information entre situations voisines deviendrait nécessaire.

5 Erreur d'estimation et quantité de données

5.1 Comportement asymptotique

Proposition 7. *Soit f le vecteur des fréquences de m tirages indépendants de loi $\pi \in \Delta_K$, avec $\pi(k) > 0$ pour tout k. Lorsque toutes les fréquences sont strictement positives,*

$$\mathrm{KL}(\pi \,\|\, f) = \frac{1}{2} \sum_{k} \frac{\big(f(k) - \pi(k)\big)^2}{\pi(k)} + O_P\big(m^{-3/2}\big), \qquad \mathbb{E}\Big[\frac{1}{2} \sum_{k} \frac{\big(f(k) - \pi(k)\big)^2}{\pi(k)}\Big] = \frac{K-1}{2m}.$$

Démonstration. On pose $\delta_k = f(k) - \pi(k)$; on a $\sum_k \delta_k = 0$ et $\delta_k = O_P(m^{-1/2})$. Le développement $-\log(1+u) = -u + u^2/2 + O(u^3)$ appliqué à $u = \delta_k/\pi(k)$ donne

$$\mathrm{KL}(\pi \,\|\, f) = -\sum_{k} \pi(k) \log\Big(1 + \frac{\delta_k}{\pi(k)}\Big) = -\sum_{k} \delta_k + \frac{1}{2} \sum_{k} \frac{\delta_k^2}{\pi(k)} + O_P\big(m^{-3/2}\big),$$

et le terme linéaire est nul. Pour la loi multinomiale, $\mathbb{E}[\delta_k^2] = \pi(k)\big(1-\pi(k)\big)/m$, d'où $\mathbb{E}\big[\tfrac{1}{2}\sum_k \delta_k^2/\pi(k)\big] = \sum_k \big(1-\pi(k)\big)/(2m) = (K-1)/(2m)$. □

La probabilité qu'une fréquence soit nulle décroît exponentiellement avec m. Pour les tailles étudiées ici, elle est négligeable : avec 5 000 mains, une carte est observée environ 385 fois et le résultat le moins probable a une probabilité d'environ 0,06, si bien qu'il manque avec une probabilité de l'ordre de 10^{-10}.

Corollaire 1. *Pour n mains d'entraînement, l'excès moyen de log-loss de l'estimateur par fréquences vaut, à l'ordre principal,*

$$\sum_{d \in \mathcal{C}} P(d)\, \frac{K-1}{2\, n\, P(d)} = \frac{|\mathcal{C}|\,(K-1)}{2n} = \frac{25}{n}.$$

Démonstration. La carte d est observée environ $n_d \approx n\,P(d)$ fois ; on applique la proposition 7 à chaque carte, puis on pondère par $P(d)$. □

Ce résultat ne dépend pas de la loi des cartes visibles : une carte rare est estimée moins précisément, mais elle pèse moins dans le risque, et les deux effets se compensent exactement. L'erreur diminue comme $1/n$: il faut multiplier le nombre de mains par dix pour diviser l'excès par dix.

Pour la régression régularisée, la proposition 6 montre que $q_d - f_d = O(1/n_d)$. Cette correction ne modifie le développement de la proposition 7 qu'aux ordres supérieurs, et l'excès de la régression suit donc la même loi $25/n$ à l'ordre principal. Pour de petits échantillons, la correction n'est plus négligeable : avec 5 000 mains, $C\,n_d$ vaut environ 38 au lieu de 460, et l'attraction vers la loi commune réduit un peu la variance de l'estimation. C'est cohérent avec le léger avantage, non significatif, de la régression observé à cette taille.

5.2 Comparaison avec les mesures

L'étude de la quantité de données répète l'entraînement sur cinq jeux indépendants pour quatre tailles. Le tableau 1 et la figure 1 comparent les excès moyens mesurés à la prédiction du corollaire 1.

Mains d'entraînement n	Prédiction $25/n$	Fréquences (mesure)	Régression (mesure)
5 000	0,005000	0,005007	0,004507
20 000	0,001250	0,001310	0,001257
60 000	0,000417	0,000434	0,000424
200 000	0,000125	0,000119	0,000129

TABLE 1 – Excès de log-loss moyen sur cinq jeux indépendants, comparé à la prédiction asymptotique.

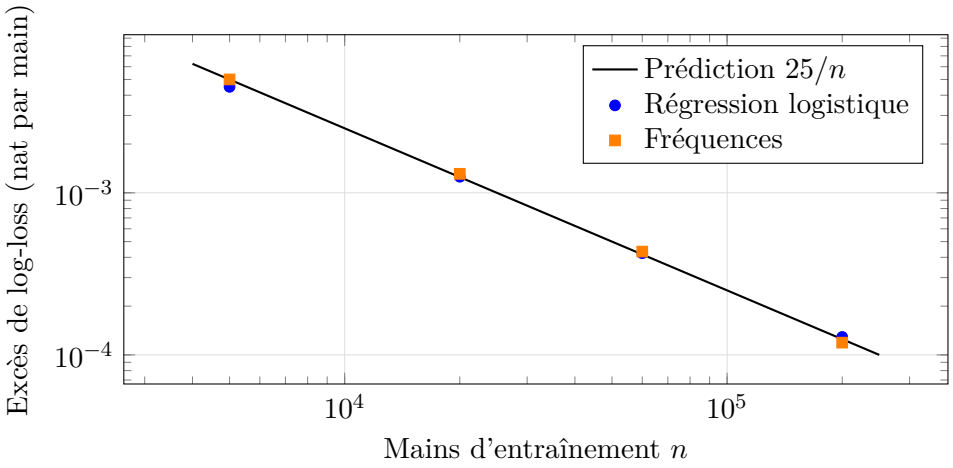


FIGURE 1 – Excès de log-loss moyen en fonction du nombre de mains, en échelle logarithmique. La droite de pente -1 est la prédiction du corollaire 1.

Sur deux ordres de grandeur de taille d'échantillon, les fréquences suivent la prédiction à moins de 5 % près. La régression la suit de la même manière, sauf à 5 000 mains où elle fait 10 % mieux, pour la raison donnée ci-dessus. L'erreur résiduelle du modèle 1 s'explique donc entièrement par la taille finie des données : le modèle saturé n'a pas de biais d'approximation, et il n'y a pas de surapprentissage à corriger.

Remarque (Dispersion d'une carte à l'autre). La quantité $2m \cdot \frac{1}{2}\sum_k \delta_k^2/\pi(k)$ est la statistique du χ^2 de Pearson. Asymptotiquement, $2\,n_d \mathrm{KL}(\pi_d \,\|\, f_d)$ suit donc approximativement une loi du χ^2 à $K-1=5$ degrés de liberté, de moyenne 5 et d'écart-type $\sqrt{10} \approx 3{,}2$. Dans le jeu d'entraînement livré, cette quantité vaut en moyenne 5,4 sur les dix cartes. Elle atteint 13,7 pour la carte 6, une valeur qu'une loi du χ^2 à cinq degrés de liberté dépasse avec une probabilité de 1,8 %. Sur dix cartes, la probabilité qu'au moins une atteigne une telle valeur est de 16 % : c'est une fluctuation ordinaire. Elle explique toutefois pourquoi la carte 6 concentre les plus grandes erreurs du modèle livré (section 6).

6 De l'erreur des probabilités à l'erreur de décision

6.1 Erreur sur la valeur de rester

Proposition 8. *Pour tout total p et toute carte d,*

$$|\hat{V}_{STAND}(p,d) - V_{STAND}(p,d)| \le 2\,\mathrm{TV}(q_d,\pi_d) \le \sqrt{2\,\mathrm{KL}(\pi_d \,\|\, q_d)}.$$

De plus, pour $p \le 16$, $\hat{V}_{STAND}(p,d) - V_{STAND}(p,d) = 2\big(q_d(BUST) - \pi_d(BUST)\big)$.

Démonstration. La première inégalité est le lemme sur la variation totale du document du modèle 2 (section 6). La seconde est l'inégalité de Pinsker, $\mathrm{TV}(\pi,q) \le \sqrt{\mathrm{KL}(\pi \,\|\, q)/2}$ [1]. Enfin, pour $p \le 16$, le joueur ne gagne que si le croupier dépasse 21, donc $V_{\mathrm{STAND}}(p,d) = 2\pi_d(\mathrm{BUST}) - 1$, et de même pour $\hat{V}_{\mathrm{STAND}}$ (section 2 du document du modèle 2). □

En combinant cette proposition avec la proposition 7, on obtient l'ordre de grandeur typique de l'erreur sur la valeur de rester :

$$|\hat{V}_{\mathrm{STAND}} - V_{\mathrm{STAND}}| \lesssim \sqrt{2 \cdot \frac{K-1}{2\,n_d}} = \sqrt{\frac{5}{n\,P(d)}}.$$

Avec $n = 60\,000$, cela donne environ 0,033 pour une carte de 1 à 9 et 0,017 pour la carte 10. L'erreur ne décroît qu'en $1/\sqrt{n}$: la diviser par deux demande quatre fois plus de mains.

Pour le modèle livré, la plus grande distance en variation totale vaut $\varepsilon_{TV} = 0{,}0229$ et est atteinte pour la carte 6, d'où la borne $\eta = 2\varepsilon_{TV} = 0{,}0457$. L'erreur maximale effectivement observée sur V_{STAND} vaut 0,0387, dans l'état $(17, 6, 0)$. Pour les totaux inférieurs ou égaux à 16, l'erreur provient uniquement de la probabilité de dépassement : pour la carte 6, le modèle annonce 0,4041 au lieu de 0,4232, ce qui donne une erreur de $2 \times 0{,}0191 = 0{,}0382$.

6.2 Conséquences pour la politique

Le document du modèle 2 (section 6) établit trois résultats qui relient η à la politique hybride limite, c'est-à-dire à celle qu'obtiendrait le Q-learning hybride après un nombre infini d'épisodes :

1. la valeur de HIT limite vérifie $|\hat{Q}_{\mathrm{HIT}} - Q^*_{\mathrm{HIT}}| \le \eta$ dans tout état ;
2. la décision ne peut différer de la décision optimale que dans les états *ambigus*, où $|Q^*_{\mathrm{HIT}} - V_{\mathrm{STAND}}| \le 2\eta$;
3. la perte de gain est au plus $36\,\eta$.

Le tableau 2 confronte ces bornes aux valeurs calculées pour le modèle livré, en résolvant les équations de Bellman avec $\hat{V}_{\mathrm{STAND}}$.

Quantité	Borne théorique	Valeur calculée
Erreur maximale sur V_{STAND}	$\eta = 0{,}0457$	0,0387
Erreur maximale sur Q_{HIT}	$\eta = 0{,}0457$	0,0370
États où la décision peut différer	27 états ambigus sur 280	1 état sur 280
Perte de gain espéré par partie	$36\,\eta = 1{,}65$	0,000022

TABLE 2 – Bornes du document du modèle 2 et valeurs obtenues avec le modèle 1 livré.

Les bornes sur les valeurs sont proches des erreurs observées, mais les bornes sur la politique sont très pessimistes. Le seul état où la décision change est $(12, 4, 0)$: la politique optimale y reste, car $V_{\mathrm{STAND}} = -0{,}2111$ dépasse $Q^*_{\mathrm{HIT}} = -0{,}2135$ de seulement 0,0025, alors que la politique hybride limite tire, car $\hat{Q}_{\mathrm{HIT}} = -0{,}2239$ dépasse $\hat{V}_{\mathrm{STAND}} = -0{,}2273$. La perte qui en résulte, 0,000022 par partie, est négligeable devant l'écart de 0,00065 qui sépare l'agent livré de l'optimum après 100 000 épisodes.

Remarque (Pourquoi les erreurs se compensent en partie). La décision dépend de la différence $\hat{Q}_{\text{HIT}} - \hat{V}_{\text{STAND}}$, et non de chaque valeur séparément. Or $\hat{Q}_{\text{HIT}}(s)$ est calculée à partir des valeurs $\hat{V}_{\text{STAND}}$ des états suivants, qui partagent la même carte visible et donc la même erreur de probabilité. Les deux erreurs vont dans le même sens et s'annulent en partie. Dans l'état $(12, 4, 0)$, la valeur de rester est sous-estimée de 0,0163 et celle de tirer de 0,0104 : leur différence ne varie que de 0,0059, alors que la borne autorise une variation de $2\eta = 0{,}0915$.

7 Protocole statistique

Choix de la régularisation. Pour chaque valeur candidate de C, la log-loss moyenne sur le jeu de validation est un estimateur sans biais du risque $\mathcal{R}(q_C)$ du modèle entraîné. Choisir la valeur qui minimise ces estimations rend en revanche le score retenu optimiste, car on sélectionne en partie le bruit de la validation. C'est pourquoi la qualité finale est mesurée sur un jeu de test distinct, généré après ce choix.

Comparaison appariée sur le test. Pour comparer deux estimateurs q et q', on calcule sur chaque main de test la différence $\Delta_i = -\log q_{d_i}(D_i) + \log q'_{d_i}(D_i)$. Le bruit dû aux cartes, commun aux deux estimateurs, disparaît en grande partie de cette différence. L'intervalle $\bar{\Delta} \pm 1{,}96\, s_\Delta/\sqrt{m}$, où s_Δ est l'écart-type empirique des $m = 12\,000$ différences, est un intervalle de confiance approximatif à 95 % fondé sur le théorème central limite. Entre la régression et les fréquences, il vaut $[-0{,}000125\,;\, +0{,}000014]$ et contient zéro.

Répétitions indépendantes. Pour l'étude de la quantité de données, l'unité statistique est le jeu de données complet. Avec cinq jeux, l'intervalle de confiance de la moyenne utilise le quantile de Student à quatre degrés de liberté, $t_{0{,}975} = 2{,}776$, au lieu de 1,96. Les tailles d'entraînement d'une même répétition sont des préfixes du même jeu : les statistiques sont donc calculées entre répétitions, à taille fixée.

Calibration par issue. La figure de calibration du dépôt compare chaque probabilité prédite à la fréquence observée sur le test, avec un intervalle de Wilson [5]. Pour une proportion observée $\hat{p}$ sur m mains et $z = 1{,}96$, cet intervalle vaut

$$\frac{\hat{p} + \frac{z^2}{2m} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{m} + \frac{z^2}{4m^2}}}{1 + \frac{z^2}{m}}.$$

Il reste fiable pour les petites proportions, contrairement à l'intervalle $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/m}$. Les soixante intervalles sont calculés point par point : ils ne forment pas une bande de confiance simultanée, et quelques points hors de leur intervalle sont attendus même pour un modèle parfait.

8 Synthèse

Le modèle 1 estime dix lois de probabilité à partir d'une seule variable catégorielle. Dans ce cadre, la régression logistique multinomiale est un modèle saturé : sans régularisation, elle redonne exactement les fréquences observées, et la régularisation ne l'en écarte que d'une quantité inversement proportionnelle à $C\, n_d$. Son erreur suit la loi asymptotique $25/n$ de l'estimation par fréquences, ce que confirment les mesures sur deux ordres de grandeur. Cette erreur se transmet à la valeur de rester avec une amplitude de l'ordre de $\sqrt{5/(n\, P(d))}$, soit quelques centièmes pour 60 000 mains. Elle ne modifie pourtant la politique limite que dans un seul des 280 états, pour une perte de gain négligeable. Ces résultats expliquent pourquoi l'ablation ne distingue pas la régression des fréquences, et pourquoi l'avantage de l'agent hybride tient à l'information apportée par les mains simulées plutôt qu'à la forme du classifieur.

Références

[1] T. M. Cover et J. A. Thomas, *Elements of Information Theory*, 2e édition, Wiley, 2006.

[2] T. Gneiting et A. E. Raftery, « Strictly proper scoring rules, prediction, and estimation », *Journal of the American Statistical Association*, 102(477), 2007, p. 359–378.

[3] T. Hastie, R. Tibshirani et J. Friedman, *The Elements of Statistical Learning*, 2e édition, Springer, 2009, chapitre 4.

[4] J. Nocedal et S. J. Wright, *Numerical Optimization*, 2e édition, Springer, 2006, chapitre 7.

[5] E. B. Wilson, « Probable inference, the law of succession, and statistical inference », *Journal of the American Statistical Association*, 22(158), 1927, p. 209–212.