Blackjack : fondements statistiques du modèle 1

Version révisée après audit scientifique

Projet d'Alessandro Daouk et Wassim Ghnaya

30 octobre 2026

Ce document révise les fondements du prédicteur supervisé introduit par Alessandro Daouk. La version antérieure est conservée au commit `9c3d631`. Le modèle livré n'est pas remplacé.

Table des matières

1 Données, cible et domaine de validité **1**

2 Scores probabilistes et erreur irréductible **1**

3 Objectif exact de la régression et identifiabilité **2**

4 Modèle saturé : ce que la logistique apporte réellement **3**

5 Pourquoi l'espérance du KL brut est infinie **3**

6 Lissage Dirichlet : une espérance finie et une vraie loi en 25/n **4**

7 De la prédiction aux décisions **5**

8 Inférence et limites des garanties **5**

1 Données, cible et domaine de validité

Dans Blackjack-v1, `natural=False`, `sab=False`, les cartes sont indépendantes avec remise. Leur loi est $q_d = 1/13$ pour $d = 1, \ldots, 9$ et $q_{10} = 4/13$. Le croupier s'arrête sur tout total au moins égal à 17, y compris 17 souple. On observe (d, D), carte visible et issue finale, avec $D \in \{17, 18, 19, 20, 21, 22\}$, où 22 code le dépassement. On écrit $\pi_d(k) = P(D = k \mid d)$, $K = 6$ et $L = 10$. Les n mains d'un jeu sont i.i.d. ; N_d et N_{dk} désignent les effectifs.

Proposition 1 (Suffisance de la carte visible)**.** *Conditionnellement à d, l'issue du croupier est indépendante de la main et des choix du joueur. Pour un état $s = (p, d, a)$ où le joueur reste, $P(D = k \mid s) = \pi_d(k)$.*

Démonstration. Les cartes du joueur et celles du croupier sont des tirages indépendants. La règle d'arrêt du croupier dépend seulement de ses propres cartes. Conditionner sur la carte visible ne crée aucune dépendance avec les cartes du joueur. L'absence de *peek* (conditionnement sur l'absence de blackjack) est essentielle. □

Cette propriété ne s'étend pas telle quelle au paquet fini. Il reste 50 probabilités libres, et non un problème de prédiction certaine du prochain résultat. L'oracle énumère les issues pour *évaluer* les estimateurs. Les étiquettes des modèles appris proviennent du simulateur. Seuls les bras nommés *oracle* et les expériences mathématiques multinomiales utilisent directement la loi exacte.

2 Scores probabilistes et erreur irréductible

Pour un prédicteur $u_d(k)$, son risque logarithmique est

$$R(u) = -\sum_d q_d \sum_k \pi_d(k) \log u_d(k) = H(D \mid d) + \sum_d q_d \, \mathrm{KL}(\pi_d \| u_d).$$

La décomposition s'obtient en ajoutant et soustrayant $\log \pi_d(k)$. Elle reste vraie au sens étendu avec risque infini si $u_d(k) = 0 < \pi_d(k)$. La log-loss est strictement propre : Gibbs donne $\mathrm{KL} \geq 0$ [3], avec égalité uniquement pour la vraie distribution. Le Brier multiclasse vérifie

$$\mathbb{E} \sum_k (u_d(k) - \mathbf{1}[D = k])^2 = \sum_d q_d \{ \|u_d - \pi_d\|_2^2 + 1 - \|\pi_d\|_2^2 \}.$$

La preuve utilise $\mathbb{E}\mathbf{1}[D = k] = \pi_d(k)$ et développe le carré. Ces deux scores évaluent les probabilités, contrairement à l'accuracy et au F1 macro qui ne portent que sur la classe annoncée [1].

L'entropie conditionnelle exacte est environ 1,648102 nat par main ; l'accuracy optimale de classification est environ 36,70 %. Une faible accuracy n'indique donc pas à elle seule un mauvais prédicteur. Une réalisation finie de test peut favoriser un modèle estimé plutôt que la vraie loi, alors que cette dernière minimise le risque en espérance.

Calibration. Les dix entrées étant discrètes, on peut comparer les 60 probabilités à leurs fréquences de test et à la référence exacte. Les intervalles de Wilson ponctuels ne sont pas simultanés. Nous n'utilisons pas d'ECE agrégée par classes de confiance : un choix de discrétisation ajouterait une convention inutile ici. La référence exacte fournit une mesure plus directe de l'erreur.

Convention numérique. La log-loss *sur échantillon* historique écrête les probabilités à l'epsilon machine pour éviter un logarithme de zéro. Ce score numérique n'est pas un KL mathématique non écrêté. Le code révisé `src/supervised/evaluate.py` distingue désormais le KL exact et sa version écrêtée. Les résultats historiques sans zéro restent inchangés.

3 Objectif exact de la régression et identifiabilité

La carte d est encodée par $e_d \in \mathbb{R}^{10}$. Avec $W \in \mathbb{R}^{6\times 10}$ et $b \in \mathbb{R}^6$,

$$u_d(k) = \frac{\exp(W_{kd} + b_k)}{\sum_j \exp(W_{jd} + b_j)}.$$

Le pipeline utilise L-BFGS, `max_iter=2000`, `tol=1e-9`, sans poids de classes ni d'exemples. Pour scikit-learn **1.9.1**, l'objectif est

$$\frac{1}{n} \sum_i -\log u_{d_i}(D_i) + \frac{\|W\|_F^2}{2Cn}, \tag{1}$$

soit, à un facteur positif près, $\mathcal{L}_C = \|W\|_F^2/2 + C \sum_i -\log u_{d_i}(D_i)$. Le biais n'est pas pénalisé. Ceci est vérifié dans le source installé (`l2_reg_strength=1/(C*sw_sum)`), et pas déduit d'une convention supposée universelle. Les résidus numériques sont enregistrés dans `results/v2/diagnostics/sklearn_objective.json` [2].

Proposition 2 (Existence et convexité sur un quotient)**.** *Soit $C > 0$, avec chaque classe observée au moins une fois. L'objectif a un minimiseur fini. Il est convexe sur (W, b) et strictement convexe sur le sous-espace $\sum_k b_k = 0$. Sans cette contrainte, son unique direction plate est $(\Delta W = 0, \Delta b = c\mathbf{1})$. Le minimiseur y est unique à cette invariance près ; les probabilités ajustées sont uniques.*

Démonstration. La dérivée seconde dans une direction (A, v) vaut

$$\|A\|_F^2 + C \sum_d N_d \operatorname{Var}_{k \sim u_d}(A_{kd} + v_k) \geq 0.$$

Elle ne s'annule que si $A = 0$ et v est constant, puisque les probabilités softmax sont positives et au moins un N_d est positif. Sur $\sum v_k = 0$, elle est donc strictement positive hors de zéro. Sur un sous-niveau de l'objectif, la pénalité borne W. Si b centré diverge, au moins une classe a un score arbitrairement inférieur au score maximal, uniformément en d puisque W reste borné. Cette classe étant observée, sa perte diverge. Les sous-niveaux sur ce sous-espace sont donc compacts : le minimum est atteint. □

Sans pénalité, les invariances du paramétrage one-hot avec intercept sont plus nombreuses : un transfert de constante entre une ligne de W et son biais, ou un décalage commun des scores d'une entrée, ne change pas les probabilités. Il serait incorrect de déclarer l'objectif globalement strictement convexe sans préciser les directions et la pénalité. Une classe totalement absente peut empêcher l'existence d'un biais fini ; le pipeline refuse ces jeux.

Proposition 3 (Relations stationnaires)**.** *Pour $N_d > 0$, en notant $f_d(k) = N_{dk}/N_d$, au minimum exact,*

$$u_d(k) - f_d(k) = -\frac{W_{kd}}{CN_d}, \qquad \sum_d W_{kd} = 0, \qquad \sum_d N_d u_d(k) = \sum_d N_{dk}.$$

Démonstration. Les gradients sont $W_{kd} + CN_d(u_d(k) - f_d(k))$ et $C \sum_d N_d(u_d(k) - f_d(k))$ par rapport au biais b_k. Leur annulation donne les trois identités. □

Pour le modèle livré, le résidu maximal dans la première identité vaut $1{,}4984\,10^{-7}$; le gradient normalisé du biais est au plus $7{,}8836\,10^{-9}$. La convexité caractérise l'optimum mathématique ; un solveur arrêté à tolérance finie n'en donne qu'une approximation.

4 Modèle saturé : ce que la logistique apporte réellement

Si tous les $N_{dk} > 0$, la perte non régularisée s'écrit

$$\sum_d N_d\{H(f_d) + \mathrm{KL}(f_d \| u_d)\}.$$

Elle atteint son minimum pour $u_d = f_d$, représentable par $b = 0$ et $W_{kd} = \log f_d(k)$. Si une cellule est nulle, l'infimum peut être situé au bord du simplexe et n'est pas atteint par des poids softmax finis. La régression non régularisée et les fréquences estiment donc les mêmes dix lois, sans avantage structurel de généralisation de la première.

La pénalisation attire les colonnes vers une loi commune gouvernée par le biais, mais ne constitue pas un lissage Dirichlet exact. À C fixé, à l'intérieur du simplexe et sur des jeux suffisamment grands, les poids dans une jauge fixée sont $O_p(1)$; la correction stationnaire est $O_p(N_d^{-1})$. Cela décrit un effet asymptotique, pas une garantie de domination en log-loss.

Un contexte plus riche pourrait justifier un partage paramétrique entre entrées, mais ni la nécessité d'une régression particulière, ni sa supériorité dans un paquet fini ne sont démontrées ici.

5 Pourquoi l'espérance du KL brut est infinie

Proposition 4 (Un événement rare ne rend pas l'infini négligeable)**.** *Pour $m \geq 1$ tirages d'une loi π intérieure au simplexe avec $K \geq 2$, les fréquences f vérifient $\mathbb{E}\,\mathrm{KL}(\pi \| f) = +\infty$.*

Démonstration. Pour n'importe quelle classe k, $P(N_k = 0) = (1 - \pi_k)^m > 0$. Sur cet événement, $\pi_k \log(\pi_k / f_k) = +\infty$. Le KL étant positif, son espérance étendue est infinie. Le caractère exponentiellement rare de l'événement ne change pas cette conclusion. □

Avec entrées aléatoires, l'événement $N_d > 0, N_{dk} = 0$ a probabilité $(1-q_d\pi_d(k))^n-(1-q_d)^n > 0$. Une convention uniforme pour une carte jamais observée ne résout donc pas le problème du KL des fréquences brutes.

Proposition 5 (Développement aléatoire local)**.** *Pour π fixée intérieure, sur un événement A_m de probabilité tendant vers un, avec $\delta_k = f_k - \pi_k$,*

$$\mathrm{KL}(\pi\|f) = \frac{1}{2}\sum_k \frac{\delta_k^2}{\pi_k} + O_p(m^{-3/2}), \qquad \mathbb{E}\left[\frac{1}{2}\sum_k \frac{\delta_k^2}{\pi_k}\right] = \frac{K-1}{2m}.$$

La statistique $2m\,\mathrm{KL}(\pi\|f)$ converge en loi vers χ^2_{K-1} (après une extension arbitraire sur le complément de A_m).

Démonstration. Choisir $A_m = \{\max_k |\delta_k| \le \min_k \pi_k/2\}$. Hoeffding donne une probabilité complémentaire exponentiellement petite. Taylor uniforme de $-\log(1+\delta_k/\pi_k)$ donne le terme quadratique, car $\sum \delta_k = 0$. Le reste est borné par une constante fois $\sum |\delta_k|^3 = O_p(m^{-3/2})$. La covariance multinomiale donne $\mathbb{E}\delta_k^2 = \pi_k(1-\pi_k)/m$. Enfin, le TCL multinomial et la projection sur le sous-espace de somme nulle donnent la loi limite du carré de Pearson, χ^2_{K-1}. Les zéros hors de A_m n'autorisent pas un passage à l'espérance du KL non lissé. □

Le terme principal est *aléatoire* : remplacer celui-ci par $(K-1)/(2m)$ avec un reste $o_p(1/m)$ serait faux. Une convergence en loi n'implique pas la convergence des espérances sans contrôle d'intégrabilité.

6 Lissage Dirichlet : une espérance finie et une vraie loi en 25/n

Pour $\alpha > 0$ fixé, poser $\widetilde{f}_k = (N_k + \alpha)/(m + K\alpha)$. $\alpha = 1/2$ correspond à Jeffreys ; $\alpha = 1$ au lissage de Laplace. Ces estimateurs restent définis même pour $m = 0$.

Proposition 6 (Risque lissé, dimension fixée)**.** *Sous K fixé, $\min_k \pi_k > 0$ fixé et $\alpha > 0$ fixé,*

$$\mathbb{E}\,\mathrm{KL}(\pi\|\widetilde{f}) = \frac{K-1}{2m} + O(m^{-3/2}).$$

Pour L entrées de probabilités $q_d > 0$ fixées, avec lois conditionnelles intérieures et n mains i.i.d.,

$$\mathbb{E}\sum_d q_d\,\mathrm{KL}(\pi_d\|\widetilde{f}_d) = \frac{L(K-1)}{2n} + O(n^{-3/2}) = \frac{25}{n} + O(n^{-3/2}).$$

Les constantes peuvent dépendre de $\min \pi_d(k)$, $\min q_d$ et α.

Démonstration. Écrire $\widetilde{f}_k - \pi_k = (N_k - m\pi_k + \alpha(1 - K\pi_k))/(m + K\alpha)$. Le biais est $O(m^{-1})$ et la variance $\pi_k(1-\pi_k)/m + O(m^{-2})$. La moyenne du terme quadratique est donc $(K-1)/(2m) + O(m^{-2})$. Sur A_m, la moyenne du reste absolu de Taylor est $O(m^{-3/2})$ par les moments multinomiaux. Sur son complément, le KL est borné par $\log((m + K\alpha)/\alpha)$; sa contribution est $O(e^{-cm}\log m)$. Cela justifie cette fois le passage à l'espérance. Pour les entrées aléatoires, conditionner sur N_d. Sur $N_d \ge nq_d/2$, un développement de $1/N_d$ autour de nq_d donne $\mathbb{E}[\mathbf{1}(N_d > 0)/N_d] = 1/(nq_d) + O(n^{-2})$. Les événements restants, y compris $N_d = 0$, ont probabilité exponentiellement petite et un risque au plus logarithmique. Pondérer par q_d puis sommer donne la formule. □

Ce résultat n'est pas uniforme près du bord du simplexe ni pour un nombre de classes croissant. Il ne garantit pas une qualité donnée à un n particulier. Pour la logistique à C fixé, le même terme quadratique décrit le comportement *en probabilité* sur les jeux admissibles. Nous ne déduisons pas sans preuve supplémentaire une espérance non conditionnelle du pipeline, qui refuse certaines données rares et sélectionne C sur validation.

L'expérience `src.audit.diagnostics` génère 2 000 tables multinomiales par taille, de 50 à 200 000 observations. Il s'agit d'un contrôle mathématique utilisant la loi exacte, distinct de tout entraînement d'agent. Les KL infinis sont comptés et conservés. Une moyenne des seules réalisations finies n'est pas l'espérance du KL brut. Le contrôle de Pearson à $m = 1000$ pour la carte 6 donne moyenne 4,9813 et variance 10,7982 (limites théoriques : 5 et 10).

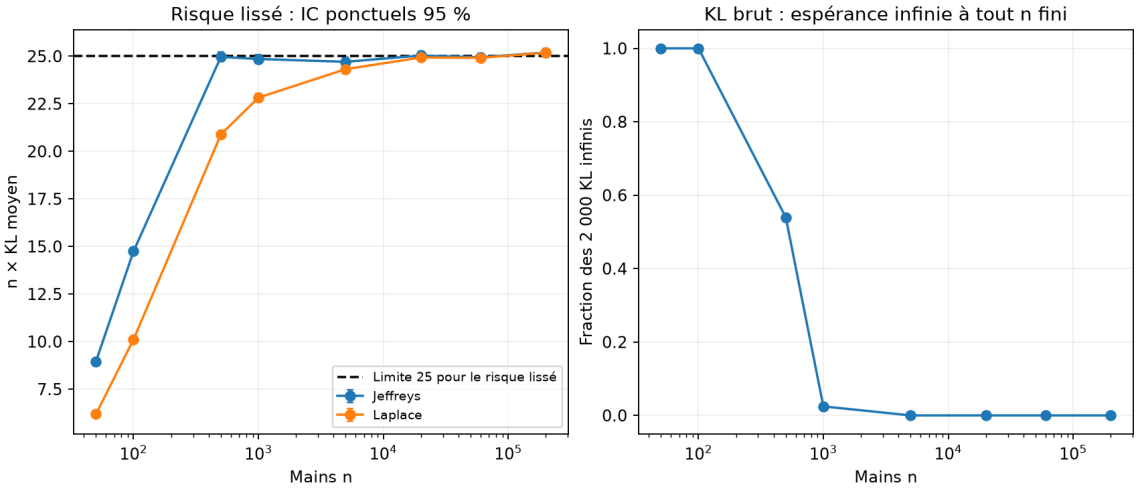


FIGURE 1 – Risque des estimateurs lissés et réalisations du KL brut. Mesures et intervalles entre répétitions indépendantes, code et graines versionnés.

7 De la prédiction aux décisions

Pour $R(p,k) \in [-1,1]$, $\widehat{V}(p,d) = \sum_k u_d(k) R(p,k)$.

Proposition 7. $|\widehat{V}(p,d) - V_{\mathrm{STAND}}(p,d)| \le 2\,\mathrm{TV}(u_d,\pi_d) \le \sqrt{2\,\mathrm{KL}(\pi_d \| u_d)}$. *Pour $p \le 16$, l'erreur vaut exactement $2(u_d(22) - \pi_d(22))$.*

Démonstration. La première inégalité est l'inégalité triangulaire avec $|R| \le 1$; la seconde est Pinsker en logarithmes naturels [3]. Sous 17, seule une issue bust rapporte $+1$, toutes les autres rapportent -1. □

Pinsker est une borne par entrée. Remplacer son KL par un KL moyen ou par $25/n$ ne donne pas une borne uniforme déterministe sur les dix entrées. L'erreur typique est d'ordre $O_p(n^{-1/2})$ dans ce modèle à dimension fixée.

Pour le prédicteur livré, $\max_d \mathrm{TV} = 0{,}02287460$ et $\eta = \|\widehat{V} - V_{\mathrm{STAND}}\|_\infty = 0{,}03870760$. Le document du modèle 2 démontre $\|\widehat{Q}^*_H - Q^*_H\|_\infty \le \eta$ et un regret de politique limite au plus 2η, non un facteur 36 multiplié par η. La borne locale pondérée par occupation vaut 0,00082724, contre un regret limite effectivement calculé de 0,0000218341. L'unique état différent est $(12, 4, 0)$; sa probabilité de visite sous cette politique est 0,00882739. Un état sur 280 n'a pas la même signification qu'une proportion de décisions réellement rencontrées.

8 Inférence et limites des garanties

Le modèle historique utilise 60 000 mains train (42), 12 000 validation (43), 12 000 test (123), $C \in \{.01, .1, 1, 10, 100\}$ choisi sur validation et sans refit. Les intervalles sur ses pertes de test conditionnent sur le modèle fixé. Ils n'estiment pas la variabilité de nouveaux jeux d'entraînement. La campagne v2 propage séparément graines supervisées et RL et calcule ses intervalles sur des grappes indépendantes, après moyenne des graines RL internes.

La faible dimension et la bonne spécification rendent plausible une faible erreur d'estimation aux tailles historiques. Elles ne prouvent ni l'absence de surapprentissage, ni l'absence d'optimisme de sélection. Un IC contenant zéro n'établit pas l'équivalence entre logistique et fréquences. Une conclusion d'équivalence exige une marge fixée à l'avance et une procédure adaptée, comme le double test unilatéral [4] : la campagne v2 fixe la marge à 0,001 par partie. Sur 9 jeux supervisés indépendants de 20 000 mains, les agents hybrides obtenus avec la logistique et avec les fréquences ont le même gain exact dans 17 paires sur 18 ; la différence moyenne vaut $-3{,}4 \cdot 10^{-6}$ et le TOST établit l'équivalence à $\pm 0{,}001$ ($p < 10^{-17}$). Cette équivalence porte sur le gain de l'agent, pas sur toutes les métriques probabilistes, et seulement dans ce problème à une variable. Les expériences n'autorisent pas de conclusion générale sur d'autres jeux ou sur un casino. Les fichiers de résultats historiques sont conservés ; les textes corrigés et les mesures v2 font foi pour les interprétations nouvelles.

Références

[1] T. Gneiting et A. E. Raftery (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *JASA*, 102(477), 359–378. doi:10.1198/016214506000001437.

[2] Scikit-learn, version installée 1.9.1. *LogisticRegression* et *LinearModelLoss*, sources vérifiées dans les résultats v2. `https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression`.

[3] T. M. Cover et J. A. Thomas (2006). *Elements of Information Theory*, deuxième édition, Wiley.

[4] D. J. Schuirmann (1987). A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability. *Journal of Pharmacokinetics and Biopharmaceutics*, 15(6), 657–680. doi:10.1007/BF01068419.