Blackjack : fondements du Q-learning hybride

Version révisée après audit scientifique

Projet d'Alessandro Daouk et Wassim Ghnaya

30 octobre 2026

Le modèle 2 et sa première analyse sont dus à Wassim Ghnaya. Cette révision explicite les hypothèses, corrige la borne de durée et renforce la borne de regret. Les sources de son algorithme restent inchangées ; le texte antérieur est conservé au commit `6f397e8`. Les nouvelles expériences ne remplacent pas les modèles livrés.

Table des matières

1 MDP fini et règles exactes **1**

2 Valeurs exactes et modèle partiellement estimé **2**

3 Apprentissage et convergence conditionnelle **2**

4 Ce que la réduction de variance démontre, et ce qu'elle ne démontre pas **4**

5 Propagation de l'erreur et regret de la politique limite **4**
5.1 Borne locale sur le DAG et occupation 5
5.2 Agent fini et limites des garanties 5

6 Vérifications numériques reproductibles **5**

7 Paramètres et interprétation expérimentale **6**

1 MDP fini et règles exactes

Les cartes sont tirées indépendamment avec remise : $P(c) = 1/13$ pour $c = 1, \dots, 9$ et $P(10) = 4/13$. L'état observé est $s = (p, d, a)$, total du joueur, carte visible du croupier et indicatrice d'as utilisable. La carte cachée n'est pas observée. Les actions sont STAND (0) et HIT (1). STAND termine la manche ; le croupier tire jusqu'à 17 et reste sur 17 souple. Le gain est $+1$, 0 ou -1, sans prime de blackjack naturel (`natural=False`, `sab=False`), ni split, double ou assurance.

Le total dur vaut $h = p - 10a$. Pour HIT et la nouvelle carte c,

$$h' = h + c, \quad a' = \mathbf{1}[(a = 1 \text{ ou } c = 1) \text{ et } h' + 10 \leq 21], \quad p' = h' + 10a'.$$

Si $h' > 21$, la partie termine avec -1 ; sinon la récompense immédiate est nulle et le nouvel état est (p', d, a'). Un as déjà inutilisable ne peut redevenir utilisable puisque le total dur augmente. Cet état est donc markovien.

Proposition 1 (Atteignabilité et horizon)**.** *Il y a 280 états de décision atteignables :* $18 \times 10 = 180$ *états durs* ($p = 4, \dots, 21$)*, et* $10 \times 10 = 100$ *états souples* ($p = 12, \dots, 21$)*. Le total dur initial minimal est* ***2****, pour deux as. Chaque HIT augmente strictement* h*. Une partie comporte au plus 19 HIT non terminaux puis une dernière décision, soit au plus* ***20 décisions****.*

Démonstration. Toute main initiale a au moins deux cartes positives. Si elle est souple, $2 \le h \le 11$, donc $12 \le p \le 21$; chaque total souple est obtenu par un as et une carte de 1 à 10. Sans as utilisable, le total minimal est 4, obtenu avec deux deux. Les totaux durs de 4 à 20 sont obtenus avec deux cartes sans as ; 21 est obtenu par un tirage supplémentaire. Les dix cartes visibles ont toutes une probabilité positive et sont indépendantes de la main du joueur. Aucun autre état non terminal n'est possible. Le total dur augmente d'au moins un jusqu'à 21, d'où l'horizon annoncé. Il est atteignable avec des as répétés, même si un tel chemin est extrêmement rare. □

La borne antérieure de 18 décisions oubliait les mains initiales souples de total dur 2 ou 3. L'algorithme utilisait déjà tous les états ; c'était une erreur de preuve, pas une erreur dans les tableaux de valeurs.

Le graphe est acyclique (DAG). $\gamma = 1$ est licite : toutes les politiques terminent en temps borné ; ce sont des politiques *propres* au sens des problèmes de plus court chemin stochastique [7]. Les valeurs se calculent par total dur décroissant, de 21 à 2. La loi initiale μ_0 énumère les deux cartes du joueur et la carte visible indépendante ; elle somme à un. Gymnasium tire aussi une carte cachée, sans influencer l'état initial. Il n'y a pas de troncature dans cet environnement.

2 Valeurs exactes et modèle partiellement estimé

Avec $D \in \{17, 18, 19, 20, 21, \text{BUST}\}$, poser

$$R(p, D) = \begin{cases} 1 & D = \text{BUST ou } D < p, \\ 0 & D = p, \\ -1 & D > p, \end{cases} \qquad V_{\text{STAND}}(s) = \sum_D P(D \mid d) R(p, D).$$

Le prédicteur fournit $\widehat{V}(s)$ en remplaçant P par $\widehat{P}$. Les deux valeurs sont dans $[-1, 1]$, indépendantes de a à total fixé, et croissantes en p. Sous 17, $V_{\text{STAND}} = 2P(\text{BUST} \mid d) - 1$.

La vraie valeur optimale de HIT vérifie

$$Q^*_{\text{HIT}}(s) = \sum_c P(c) \begin{cases} -1 & h + c > 21, \\ \max\{Q^*_{\text{HIT}}(s'), V_{\text{STAND}}(s')\} & h + c \le 21. \end{cases} \tag{1}$$

Sa solution unique s'obtient par récurrence sur le DAG. La valeur optimale est $W^*(s) = \max\{Q^*_{\text{HIT}}(s), V_{\text{STAND}}(s)\}$. On définit *séparément* $\widehat{Q}^*_H$ et $\widehat{W}^*$ en remplaçant V_{STAND} par $\widehat{V}$ dans cette équation. La politique modèle limite $\widehat{\pi}$ choisit HIT si $\widehat{Q}^*_H > \widehat{V}$, STAND sinon. La politique réellement entraînée π_N remplace $\widehat{Q}^*_H$ par la table finie $Q_{H,N}$. Ces trois fonctions ne sont pas interchangeables.

L'oracle exact de Wassim utilise la récurrence du croupier puis celle du joueur. L'audit utilise une seconde implémentation : masses du croupier propagées vers l'avant, transitions obtenues à partir de mains explicites, puis système triangulaire de valeurs. Si P_H est la matrice sous-stochastique de HIT, b la probabilité de bust et $u(s)$ la probabilité de HIT sous une politique,

$$(I - \text{diag}(u) P_H) W^u = (1 - u) V_{\text{STAND}} - ub, \qquad J(u) = \mu_0^\top W^u.$$

La matrice est triangulaire après classement topologique, donc inversible. Cette formule traite aussi la politique random, avec $u(s) = 1/2$. La loi exacte n'entre dans les mises à jour de l'agent supervisé ou standard. Le bras *hybride exact* reçoit volontairement V_{STAND} : c'est une référence privilégiée et non une méthode à données égales.

3 Apprentissage et convergence conditionnelle

Le Q-learning hybride observe un HIT, puis met à jour

$$Q_H(s) \leftarrow Q_H(s) + \alpha_{N(s,H)}[Y - Q_H(s)], \quad Y = \begin{cases} r & \text{terminal,} \\ r + \max(Q_H(s'), \widehat{V}(s')) & \text{sinon.} \end{cases}$$

STAND ne met pas à jour sa valeur figée. Le standard apprend aussi STAND avec cible égale au gain terminal observé. Aucune transition terminale ne comporte un terme de bootstrap. Une troncature n'est pas une défaite ; le pipeline v2 la refuse explicitement plutôt que d'apprendre un épisode incomplet.

Lemme 1 (Approximation stochastique scalaire)**.** *Soit $(\mathcal{F}_n)$ une filtration. Supposer $x_{n+1} = (1-\alpha_n)x_n + \alpha_n(\theta + e_n + M_{n+1})$ avec des pas déterministes $0 < \alpha_n \leq 1$, $\sum \alpha_n = \infty$, $\sum \alpha_n^2 < \infty$; e_n $\mathcal{F}_n$-mesurable et $e_n \to 0$ presque sûrement ; M_{n+1} $\mathcal{F}_{n+1}$-mesurable, $\mathbb{E}[M_{n+1} \mid \mathcal{F}_n] = 0$ et $\mathbb{E}[M_{n+1}^2 \mid \mathcal{F}_n] \leq K$. Alors $x_n \to \theta$ p.s.*

Démonstration. C'est le cas scalaire du théorème de Robbins–Monro [8] ; on en donne une preuve complète. Poser $\pi_{k,n} = \prod_{j=k+1}^{n-1}(1-\alpha_j)$ pour $k < n$ (produit vide égal à 1) et $\Delta_n = x_n - \theta$. Par récurrence,

$$\Delta_n = \pi_{-1,n}\Delta_0 + \sum_{k=0}^{n-1} \alpha_k \pi_{k,n} e_k + \sum_{k=0}^{n-1} \alpha_k \pi_{k,n} M_{k+1}.$$

Poids. Comme $1 - a \leq e^{-a}$, $\pi_{k,n} \leq \exp(-\sum_{j=k+1}^{n-1} \alpha_j) \to 0$ quand $n \to \infty$ pour tout k fixé. Par télescopage, $\sum_{k=m}^{n-1} \alpha_k \pi_{k,n} = 1 - \pi_{m-1,n} \leq 1$, et pour m fixé $\sum_{k<m} \alpha_k \pi_{k,n} = \pi_{m-1,n} - \pi_{-1,n} \leq \pi_{m-1,n} \to 0$.

Termes initial et de biais. Le premier terme tend vers zéro. Pour le second, fixer m : il est majoré en valeur absolue par $\pi_{m-1,n} \max_{k<m} |e_k| + \sup_{k \geq m} |e_k|$, de limite supérieure au plus $\sup_{k \geq m} |e_k|$, qui tend vers zéro avec m.

Terme de bruit. $S_n = \sum_{k<n} \alpha_k M_{k+1}$ est une martingale de carré intégrable : $\mathbb{E}[S_n^2] = \sum_{k<n} \alpha_k^2 \mathbb{E}[M_{k+1}^2] \leq K \sum_k \alpha_k^2 < \infty$. Elle converge donc p.s. vers S_∞ (théorème de convergence des martingales bornées dans L^2). Avec $T_k = S_k - S_\infty \to 0$, une sommation par parties donne

$$\sum_{k=0}^{n-1} \alpha_k \pi_{k,n} M_{k+1} = \sum_{k=0}^{n-1} \pi_{k,n}(T_{k+1} - T_k) = T_n - \pi_{0,n} T_0 - \sum_{k=1}^{n-1} \alpha_k \pi_{k,n} T_k,$$

car $\pi_{k,n} - \pi_{k-1,n} = \alpha_k \pi_{k,n}$ et $\pi_{n-1,n} = 1$. Le dernier terme se traite exactement comme le terme de biais, avec $T_k \to 0$ à la place de e_k ; les deux premiers tendent vers zéro. Donc $\Delta_n \to 0$ p.s. □

Proposition 2 (Convergence sur ce DAG)**.** *Supposer : (i) loi de transition stationnaire conforme au MDP ; (ii) données supervisées indépendantes puis $\widehat{V} \in [-1,1]$ figée ; (iii) chaque couple pertinent (s,H) est mis à jour infiniment souvent (les deux actions pour le standard) ; (iv) initialisation dans $[-1,1]$; (v) $\alpha_n = n^{-\omega}$, $1/2 < \omega \leq 1$. Alors $Q_{H,N} \to \widehat{Q}_H^*$ p.s. pour l'hybride et $Q_N \to Q^*$ p.s. pour le standard. Cela n'affirme pas que $\widehat{Q}_H^* = Q_{\mathrm{HIT}}^*$.*

Démonstration. Les tables restent bornées : toute mise à jour est une combinaison convexe de la valeur courante et d'une cible dans $[-1,1]$, car les récompenses non terminales sont nulles. Sur la suite des visites d'un couple, soustraire à la cible son espérance conditionnelle donne un bruit de martingale borné. Au plus grand total dur, les cibles sont terminales et le lemme s'applique. Par induction descendante, toutes les valeurs suivantes convergent ; la continuité 1-lipschitz du maximum rend alors leur erreur dans l'espérance de la cible évanescente. Appliquer le lemme à chaque couple, en nombre fini. Pour le standard, STAND est une récompense terminale stationnaire, ce qui initialise la même induction. Les deux sommes de pas sont nécessaires dans cet argument, mais ne remplacent ni visitation ni contrôle du bruit. □

C'est une spécialisation au graphe absorbant des arguments de convergence du Q-learning tabulaire [1], pas une borne de vitesse à budget fini. Le cas non actualisé où toutes les politiques sont propres est couvert, sous des hypothèses de pas et de visitation analogues, par les théorèmes d'approximation stochastique asynchrone de Tsitsiklis et de Jaakkola, Jordan et Singh [8, 9]. La preuve ci-dessus n'utilise pas de contraction : l'acyclicité permet une induction finie, ce qui rend explicite le rôle de chaque hypothèse. Avec $\varepsilon \geq \varepsilon_{\min} > 0$, chaque action a probabilité conditionnelle au moins $\varepsilon_{\min}/2$. Chaque état atteignable admet un chemin de longueur bornée et de probabilité positive depuis un reset. Il existe donc une borne positive, dépendant de l'état, sur sa probabilité de visite par épisode, quelle que soit l'histoire ; les visites pertinentes sont infinies presque sûrement. À budget fini, les états rares peuvent rester peu visités.

Hors politique. Même pour $\varepsilon = 1$, le comportement est aléatoire mais la cible contient un maximum. La politique apprise est gloutonne, pas la politique de comportement. Expected SARSA, au contraire, moyenne sur les actions suivantes d'une politique donnée [12] ; notre intégration porte sur l'issue du croupier après une action terminale [2]. Cette issue ne dépend plus d'aucune décision : sa valeur ressemble à celle d'un *après-état* (Sutton et Barto, §6.8), dont la loi serait ici estimée hors ligne plutôt qu'apprise par différences temporelles. Ce n'est pas non plus un façonnage de récompense par potentiel [13] : la valeur de STAND remplace une estimation apprise et peut modifier la politique optimale du modèle si elle est erronée, alors qu'un potentiel préserve exactement la politique optimale.

4 Ce que la réduction de variance démontre, et ce qu'elle ne démontre pas

Pour une variable Y de carré intégrable, $\mathrm{Var}(\mathbb{E}[Y \mid d]) \leq \mathrm{Var}(Y)$, par décomposition de la variance [3]. L'espérance exacte du gain de STAND élimine son bruit conditionnel de résultat. Une estimation apprise reste toutefois aléatoire entre jeux et peut être biaisée. Les cibles de HIT incluent un maximum et un état suivant aléatoire : elles ne sont pas automatiquement une Rao–Blackwellisation des cibles standard sur la même tribu.

La convexité donne $\mathbb{E}\max(X, Y) \geq \max(\mathbb{E}X, \mathbb{E}Y)$ pour des variables intégrables. Elle n'établit pas que toutes les Q-tables ont un biais positif par rapport aux vraies valeurs (elles ne sont pas nécessairement sans biais). Remplacer un des arguments par une estimation fixe peut réduire le bruit, mais ne garantit pas une diminution uniforme du biais ou de la variance. Double Q-learning sépare sélection et évaluation, mécanisme différent [4]. Apprendre une table au lieu de deux est une simplification structurelle, pas une preuve d'un facteur deux de complexité d'échantillonnage.

Enfin, pour cibles i.i.d. stationnaires de variance σ^2 et pas constant α, la variance stationnaire d'une moyenne exponentielle est $\alpha\sigma^2/(2-\alpha)$, en résolvant $v = (1-\alpha)^2 v + \alpha^2\sigma^2$. Ce calcul n'est pas une formule exacte pour les cibles adaptatives du Q-learning.

5 Propagation de l'erreur et regret de la politique limite

Poser $e(s) = |\widehat{V}(s) - V_{\mathrm{STAND}}(s)|$ et $\eta = \max_s e(s)$. Comme $|R| \leq 1$,

$$e(s) \leq \sum_D |\widehat{P} - P|(D \mid d) = 2\,\mathrm{TV}(\widehat{P}(\cdot \mid d), P(\cdot \mid d)).$$

Proposition 3 (Stabilité des valeurs et décisions)**.** $|\widehat{Q}^*_H(s) - Q^*_{\mathrm{HIT}}(s)| \leq \eta$. *Si* $|Q^*_{\mathrm{HIT}}(s) - V_{\mathrm{STAND}}(s)| > 2\eta$, $\widehat{\pi}(s)$ *choisit l'action optimale.*

Démonstration. Induction descendante : les cartes donnant bust ont la même valeur -1 ; ailleurs, $|\max(x,y) - \max(x',y')| \le \max(|x-x'|, |y-y'|)$ borne l'erreur par η. Une moyenne sous-probabiliste ne l'augmente pas. L'erreur sur la différence HIT moins STAND est au plus 2η, donc une marge strictement supérieure garde son signe. □

Proposition 4 (Une seule récompense perturbée : borne globale renforcée)**.** *Pour toute distribution initiale,* $0 \le J^* - J(\widehat{\pi}) \le 2\eta$.

Démonstration. Comparer deux MDP avec mêmes transitions HIT, mêmes gains de bust, et gain terminal moyen de STAND respectivement V_{STAND} et $\widehat{V}$. Toute politique s'arrête au plus une fois : $|J(\pi) - \widehat{J}(\pi)| \le \eta$. Puisque $\widehat{\pi}$ optimise le second MDP,

$$J(\pi^*) - J(\widehat{\pi}) = J(\pi^*) - \widehat{J}(\pi^*) + [\widehat{J}(\pi^*) - \widehat{J}(\widehat{\pi})] + \widehat{J}(\widehat{\pi}) - J(\widehat{\pi}) \le 2\eta.$$

Le terme central est non positif. Il n'est pas nécessaire de multiplier par le nombre de décisions : l'erreur de modèle ne porte que sur une récompense terminale. Cette propriété serait fausse pour des perturbations cumulées à chaque transition sans autre contrôle. □

Les bornes classiques de perte d'une politique gloutonne par rapport à une fonction de valeur approchée [10] font intervenir l'horizon effectif $1/(1-\gamma)$; elles ne s'appliquent pas telles quelles à $\gamma = 1$. L'argument ci-dessus est l'analogue direct, qui exploite le fait qu'une seule récompense terminale est perturbée et que toute politique s'arrête au plus une fois.

5.1 Borne locale sur le DAG et occupation

Définir à rebours

$$b_H(s) = \sum_{c:\,\text{non bust}} P(c)\, b(s'), \qquad b(s) = \max\{e(s), b_H(s)\}.$$

La même induction montre $|\widehat{Q}^*_H - Q^*_{\mathrm{HIT}}| \le b_H \le \eta$. Une différence d'action n'est donc possible que lorsque la marge $m(s) = |Q^*_{\mathrm{HIT}}(s) - V_{\mathrm{STAND}}(s)|$ est au plus $e(s) + b_H(s)$. Soit $d_\pi(s) = \mathbb{E}_\pi \sum_{t<T} \mathbf{1}[s_t = s]$, occupation par épisode, sans normalisation. Sur ce DAG un état est visité au plus une fois.

Proposition 5 (Identité et borne locale)**.** *Pour toute politique déterministe,*

$$J^* - J(\pi) = \sum_s d_\pi(s)[W^*(s) - Q^*(s, \pi(s))].$$

Pour la politique modèle limite,

$$J^* - J(\widehat{\pi}) \le \sum_s d_{\widehat{\pi}}(s)\, m(s)\, \mathbf{1}[m(s) \le e(s) + b_H(s)].$$

Démonstration. C'est la version non actualisée et épisodique du lemme de différence de performance [11]. Soustraire la valeur de l'action jouée à W^*, puis sommer les différences le long d'un épisode. Les termes de valeurs futures se télescopent ; il reste $W^*(s_0)$ moins le gain total. L'espérance donne l'identité, sans hypothèse asymptotique. À deux actions, le désavantage vaut zéro si l'action est optimale, et $m(s)$ sinon. La condition de stabilité locale donne la majoration. □

La borne utilise la loi vraie et la politique modèle ; c'est un outil de compréhension a posteriori, pas un certificat accessible sans modèle du jeu. Elle peut être plus ou moins informative que 2η ; prendre le minimum des deux est licite. Elle ne constitue pas une revendication de nouveauté générale.

5.2 Agent fini et limites des garanties

Les bornes précédentes concernent $\widehat{\pi}$, non toute table apprise. Si $\delta = \|Q_{H,N} - \widehat{Q}^*_H\|_\infty$, dans le MDP estimé le désavantage de l'action gloutonne finie est au plus δ par décision, car seule HIT est estimée. L'identité précédente donne donc

$$J^* - J(\pi_N) \leq 2\eta + \delta \mathbb{E}_{\pi_N} T \leq 2\eta + 20\delta.$$

On peut aussi remplacer le seuil local par $e(s) + b_H(s) + |Q_{H,N}(s) - \widehat{Q}^*_H(s)|$. Ces bornes peuvent être inutiles si les états rarement vus ont de grandes erreurs ; les tests exacts de J restent la mesure principale. La convergence n'impose pas un regret monotone au fil des épisodes. Le premier franchissement d'un seuil peut être suivi d'une rechute.

6 Vérifications numériques reproductibles

Les valeurs suivantes proviennent de `src.audit.diagnostics`, graines et résultats dans `results/2_campagne_principale/diagnostics/`.

Quantité, modèle supervisé livré	Valeur
$\eta = \|\widehat{V} - V_{\text{STAND}}\|_\infty$	0,03870760
$\|\widehat{Q}^*_H - Q^*_{\text{HIT}}\|_\infty$	0,03704807
Borne globale 2η	0,07741520
Borne locale pondérée	0,00082724
Regret exact de la politique limite	0,0000218341
États ambigus, borne globale / locale	24 / 5
États où la politique limite diffère	1 sur 280
Occupation de l'état différent $(12, 4, 0)$	0,00882739

Les bornes utilisent ici l'erreur réelle η, plus petite que le majorant $2 \max \text{TV} = 0{,}04574921$. Le modèle livré après 100 000 épisodes obtient $J = -0{,}04720665$, contre $J^* = -0{,}04655598$: son regret est 0,00065068, distinct du regret limite. Les nouvelles perturbations vers BUST et 21 conservent des probabilités valides ; leurs erreurs, occupations et regrets sont publiés, même lorsque l'hybride se dégrade.

Sur la campagne finale v2 (9 jeux supervisés de 20 000 mains, deux graines RL chacun, `results/2_campagne_principale/analyse/`), l'erreur moyenne vaut $\eta \approx 0{,}053$: la borne $2\eta \approx 0{,}105$ n'est pas informative. La borne locale moyenne vaut 0,0012 pour un regret limite réel de 0,00013, soit environ 90 fois mieux que 2η mais encore 9 fois trop large. Pour les agents entraînés 200 000 épisodes, la borne $2\eta + \delta\, \mathbb{E}_{\pi_N} T$ vaut en moyenne 0,29 pour un regret réel de 0,0006 : elle est vraie mais inutile en pratique, car $\delta \approx 0{,}12$ provient d'états rarement visités. L'identité de différence de performance est vérifiée à $1{,}7 \cdot 10^{-17}$ près sur les 418 agents. Avec 1 000 mains, le regret limite moyen ($\approx 0{,}003$) dépasse le regret du Q-learning standard à 200 000 épisodes (0,0014) : la convergence vers l'optimum du *modèle* se traduit alors par une perte mesurée face au standard.

7 Paramètres et interprétation expérimentale

Paramètre	Standard TUNED	Hybride TUNED
ε_0	1	1
$\varepsilon_{\min}$	0,4	1
Décroissance par épisode	0,99995	0,99995
ω dans $1/N^{\omega}$	1	1
γ	1	1
Budget historique	100 000	100 000

CONFIG utilisait $\varepsilon_{\min} = 0{,}05$ pour les deux méthodes. L'audit distingue réglages propres à chaque méthode et comparaison commune à $\varepsilon_{\min} = 1$. Toutes les évaluations de politique sont gloutonnes. Le tuning historique utilisait 108 entraînements ; ce coût n'est pas inclus implicitement dans une mesure de RL d'une seule graine.

Les tableaux de fréquences et de logistique utilisent les mêmes données. L'estimation directe de STAND par moyenne des $R(p, D_i)$ est algébriquement identique à la conversion des fréquences : ce contrôle ne constitue pas une nouvelle méthode indépendante. Les temps de simulation, sélection, estimation, construction des tables et RL sont séparés ; les évaluations analytiques sont chronométrées à part. Une main croupier n'est pas une partie complète. Le prédicteur peut être amorti sur plusieurs agents ; ce scénario est distinct d'une acquisition pour une tâche unique.

Le calcul exact de la stratégie du joueur par énumération des issues du croupier est ancien [14] ; notre oracle n'en revendique pas la nouveauté. L'architecture se situe dans l'utilisation de connaissances partielles [6]. Elle ne réalise pas les mises à jour de planification à partir de transitions synthétiques caractéristiques de Dyna [5]. L'apport défendable est une étude de cas contrôlée, avec preuves locales, réplications et coûts explicites, pas l'invention du Q-learning partiellement informé.

Références

[1] C. J. C. H. Watkins et P. Dayan (1992). Q-learning. *Machine Learning*, 8, 279–292. `https://www.gatsby.ucl.ac.uk/~dayan/papers/cjch.pdf`.

[2] R. S. Sutton et A. G. Barto (2018). *Reinforcement Learning : An Introduction*, 2e édition, MIT Press, chapitres 3–6 et 8. `https://mitpress.mit.edu/9780262039246/reinforcement-learning/`.

[3] D. Blackwell (1947). Conditional Expectation and Unbiased Sequential Estimation. *Annals of Mathematical Statistics*, 18(1), 105–110. doi:10.1214/aoms/1177730497.

[4] H. van Hasselt (2010). Double Q-learning. *Advances in Neural Information Processing Systems*, 23. `https://proceedings.neurips.cc/paper/2010/hash/091d584fced301b442654dd8c23b3fc9-Abstract.html`.

[5] R. S. Sutton (1990). Integrated Architectures for Learning, Planning, and Reacting Based on Approximating Dynamic Programming. *Proceedings of the Seventh International Conference on Machine Learning*, 216–224.

[6] C. R. Shelton (2002). Reinforcement Learning with Partially Known World Dynamics. *UAI*, 461–468. `https://arxiv.org/abs/1301.0601` (dépôt arXiv ultérieur, article UAI 2002).

[7] M. L. Puterman (1994). *Markov Decision Processes : Discrete Stochastic Dynamic Programming*. Wiley. doi:10.1002/9780470316887.

[8] J. N. Tsitsiklis (1994). Asynchronous Stochastic Approximation and Q-Learning. *Machine Learning*, 16, 185–202. doi:10.1007/BF00993306.

[9] T. Jaakkola, M. I. Jordan et S. P. Singh (1994). On the Convergence of Stochastic Iterative Dynamic Programming Algorithms. *Neural Computation*, 6(6), 1185–1201.

[10] S. P. Singh et R. C. Yee (1994). An Upper Bound on the Loss from Approximate Optimal-Value Functions. *Machine Learning*, 16, 227–233.

[11] S. Kakade et J. Langford (2002). Approximately Optimal Approximate Reinforcement Learning. *Proceedings of ICML*, 267–274.

[12] H. van Seijen, H. van Hasselt, S. Whiteson et M. Wiering (2009). A Theoretical and Empirical Analysis of Expected Sarsa. *IEEE ADPRL*, 177–184. doi:10.1109/ADPRL.2009.4927542.

[13] A. Y. Ng, D. Harada et S. Russell (1999). Policy Invariance under Reward Transformations : Theory and Application to Reward Shaping. *Proceedings of ICML*, 278–287.

[14] R. R. Baldwin, W. E. Cantey, H. Maisel et J. P. McDermott (1956). The Optimum Strategy in Blackjack. *Journal of the American Statistical Association*, 51(275), 429–439.